

NAIVE BAYES VE BBN YÖNTEMİ: KALP YETMEZLİĞİ SONUCU ÖLÜM TEŞHİSİ

Mahire Zühal ÖZDEMİR

Bursa Teknik Üniversitesi

19360859015@ogrenci.btu.edu.tr

Özet – Bu rapor, kalp yetmezliği verileri kullanılarak oluşturulan bir Naive Bayes sınıflandırıcısı hakkında bilgi vermektedir. Sınıflandırıcı, hastaların kalp yetmezliği durumlarını teşhis etmek için kullanılmıştır. Kalp yetmezliği genel anlamda kalbin çeşitli nedenlere bağlı olarak zarar gördüğü veya zayıfladığı durumlarda ortaya çıkan bir hastalıktır. Yılda yaklaşık 1 milyon hasta akut dekompanse kalp yetersizliği (KY) nedeniyle hastaneye yatırılmaktadır, verilere göre mortalite oranı %4'tür. Bu çalışmada, Nisan-Aralık (2015) döneminde Faysalabad-Pakistan Kardiyoloji Enstitüsü ve Müttefik Hastanesine başvuran kalp yetmezliği hastalarının sağkalım analizinde kullanılan datasetten faydalanılmıştır. Verisetine göre tüm hastalar 40 yaş ve üzerinde, sol ventrikül sistolik disfonksiyonu olan, NYHA sınıf III ve IV'e ait hastalardı. Mortaliteyi modellemek için yaş, ejeksiyon fraksiyonu, serum kreatinin, serum sodyum, anemi, trombositler, kreatinin fosfokinaz, kan basıncı, cinsiyet, diyabet ve sigara içme durumu potansiyel olarak mortaliteye katkıda bulunan faktörler olarak dikkate alınarak Cox regresyonu kullanılmıştır. Hastaların mevcut elektronik tıbbi kayıtları, semptomları, vücut özelliklerini ve klinik laboratuvar test değerlerini ölçer; bunlar, aksi takdirde tıp doktorları tarafından tespit edilemeyen kalıpları ve korelasyonları vurgulamayı amaçlayan biyoistatistik analizi yapmak için kullanıldı.BBN ve Naive bayes sınıflandırıcıları

kullanılarak yapay zeka modeli oluşturulmuştur.Bu modele göre mortalite tespiti %77 doğruluk oranında yapılabilir. Ayrıca, aynı veriseti üzerinde yapılan çalışmalarla karşılaştırılıp değerlendirme ölçütleri görselleştirilmiştir.

Anahtar Kelimler – Kalp Yetmezliği, Naive Bayes,Bayesian Belief Network, Sınıflandırıcı, Veri Analizi,Machine Learning

I. GİRİŞ

Kalp yetmezliği, kalbin yeterince kan pompalayamadığı bir durumdur. Bu durum, kalbin pompa işlevinin bozulması nedeniyle kanın vücudun diğer bölgelerine yeterince pompalanamamasından kaynaklanır. Bu durumun birçok nedeni olabilir, ancak en yaygın nedenler arasında yüksek tansiyon, koroner arter hastalığı, kalp kapağı hastalıkları, kalp kası hastalıkları ve ritim bozuklukları bulunur.

Kalp yetmezliği, özellikle yaşlılarda ve kalp hastalığı olan kişilerde daha yaygın görülür. Ayrıca, diyabet, obezite ve yüksek kan basıncı gibi diğer sağlık sorunları da kalp yetmezliği riskini artırabilir.

Belirtiler arasında nefes darlığı, yorgunluk, ödem, çarpıntı ve göğüs ağrısı bulunur. Kalp yetmezliği tedavisi, semptomların şiddetine ve nedenine bağlı olarak değişebilir. Tedavi, ilaçlar, diyet, yaşam tarzı değişiklikleri ve bazen cerrahi müdahaleler içerebilir.

Kalp yetmezliği, ciddi bir sağlık sorunu olabilir ve zamanında teşhis ve tedavi gerektirir. Belirtileriniz varsa, bir doktorla görüşmeniz ve uygun testlerin yapılması için gerektiğinde bir kardiyologa yönlendirilmeniz önerilir.

Sağlık Bakanlığı, kalp yetmezliği konusunda toplumda farkındalık oluşturmak ve hastalığın erken teşhisi ve tedavisi için çalışmalar yürütmektedir. Bakanlık, özellikle yaşlı nüfusun artması ve risk faktörlerinin yaygınlaşması nedeniyle kalp yetmezliği görülme sıklığının arttığına dikkat çekmektedir.

Türkiye Kardiyoloji Derneği Başkanı Prof. Dr. İlker Gülçin, kalp yetmezliği hastalarının doğru tedavi ve takibi ile normal bir hayat sürdürebileceklerini belirtmektedir. Gülçin, hastalığın erken tanısı ve uygun tedavi ile ölüm riskinin azaltılabileceğine ve hastaların yaşam kalitelerinin artırılabilceğine dikkat çekmektedir.

Ülkemizdeki birçok hastane ve kardiyoloji merkezi, kalp yetmezliği hastalarının tedavisinde ileri teknoloji ve yenilikçi tedavi yöntemleri kullanmaktadır. Özellikle son yıllarda geliştirilen implantable kalp cihazları ve kalp transplantasyonu gibi tedavi yöntemleri, kalp yetmezliği hastalarının hayat kalitesini artırmakta ve yaşam sürelerini uzatmaktadır.

II. METODOLOJİ

A. Naive Bayes

Naive Bayes, makine öğrenmesinde sınıflandırma yapmak için kullanılan bir algoritmadır. Naive Bayes, verilerin belirli özelliklerine dayanarak örneğin bir e-postanın spam veya spam olmadığını belirlemek gibi belirli sınıflar arasında sınıflandırma yapar.

Naive Bayes sınıflandırıcısı, Bayes teoreminin bir uygulamasıdır. Bayes teoremi, bir olayın olasılığı hakkında bilgi veren bir istatistiksel yöntemdir. Bu teorem, bir hipotez için verilen kanıtın doğruluğunu veya olasılığını belirlemek için kullanılır.

Naive Bayes sınıflandırıcısı, sınıflandırmayı yapmak için bir dizi özellik veya değişken kullanır. Bu özellikler, veri kümesindeki her örneğe atanır. Sınıflandırıcı, özellikleri ve her sınıfın olasılığını kullanarak her örneği bir sınıfa atar.

$$\text{Posterior Probability} \quad \text{Likelihood} \quad \text{Class Prior Probability}$$
$$P(c|x) = \frac{P(x|c) P(c)}{P(x)} \quad \text{Predicted Prior Probability}$$

$$P(c|x) = P(x_1|c) P(x_2|c) P(x_3|c) \dots P(x_n|c) P(c)$$

Şekil 1 : Naive Bayes Formülü

Naive Bayes sınıflandırıcısı, özelliklerin birbirinden bağımsız olduğunu varsayar. Bu nedenle, "naive" olarak adlandırılır. Bu varsayımın doğru olmadığı durumlarda sınıflandırma sonuçları doğru olmayabilir. Ancak, Naive Bayes sınıflandırıcısı, küçük veri setlerinde iyi performans gösterir ve eğitimi kolaydır.

Naive Bayes sınıflandırıcısı, farklı türlerdeki problemler için kullanılabilir. Örneğin, spam filtreleme, duygu analizi, hastalık teşhisi gibi pek çok alanda kullanılabilir. Bunun yanı sıra, birçok programlama dilinde mevcut ve uygulanması oldukça kolaydır.

Sonuç olarak, Naive Bayes sınıflandırıcısı, makine öğrenmesinde sınıflandırma yapmak


için kullanılan popüler bir denetimli öğrenme algoritmasıdır. Özellikle küçük veri setleri için uygun bir seçenektir.

B. Bayesian Belief Network

Bayesian belief network (BBN) ya da Bayes ağları, belirli bir amaç için olasılıkları tahmin etmek için kullanılan bir olasılık modelleme teknolojisidir. Bu ağlar, birbirine bağlı düğümler ve bu düğümleri birbirine bağlayan çizgilerden oluşan bir grafik yapısıdır. Her düğüm, bir değişkeni temsil eder ve bir düğümün değeri, diğer düğümlerdeki değerlere göre belirlenir.

BBN, Bayes teoremi kullanılarak hesaplanan olasılık değerlerinin etkileşimini gösterir. Bayes teoremi, bir hipotez için gözlem yapıldığında, hipotezin gerçekleşme olasılığına ilişkin tahminleri güncellemek için kullanılan bir matematiksel formüldür.

BBN, yapay zeka, veri madenciliği, finans, tıp, biyoloji, mühendislik ve diğer birçok alanda kullanılır. Örneğin, tıbbi bir BBN, belirtileri, tanıları ve tedavileri birbirine bağlar ve bu şekilde doktorların bir hastalık hakkında karar vermesine yardımcı olur.



Şekil 2 : Bayesian Belief Network

Bayesian belief network, bir dizi değişkenin birbirine bağlı olduğu bir yapısal modeldir. BBN'nin kullanımı aşağıdaki adımları içerir:

1-)Belirleyici Değişkenlerin Tanımlanması:

BBN'yi oluşturmak için ilk adım, belirleyici değişkenlerin tanımlanmasıdır. Belirleyici değişkenler, modeldeki diğer değişkenleri etkileyen değişkenlerdir.

2-)Düğümelerin ve Bağlantıların Oluşturulması:

Daha sonra, BBN'deki düğümler oluşturulur. Her düğüm, bir değişkeni temsil eder ve bu değişkenler arasındaki ilişkiler belirlenir. Bu ilişkiler, çizgilerle birbirine bağlanır.

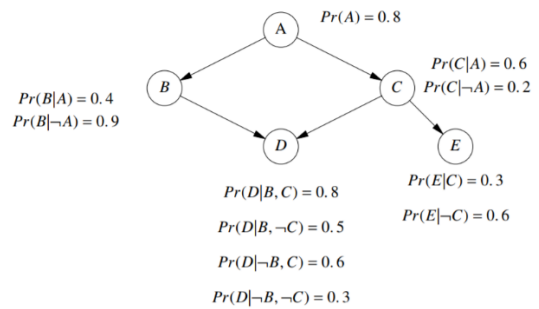
3-)İlk Olasılık Değerlerinin Atanması:

Düğüm oluşturulduktan sonra, her düğüme bir olasılık değeri atanır. Bu, her bir değişkenin olası değerlerinin ne sıklıkta ortaya çıktığını gösterir.

4-)Gözlem Yapılması: BBN, bir sonraki adımda gözlem yapar. Bu, bir veya daha fazla değişkenin değerinin bilindiği veya tahmin edildiği bir durumdur.

5-)Sonuçların Hesaplanması: Son olarak, BBN'de sonuçların hesaplanması gereklidir. Bu, tüm olasılıkların birleşmesi ile yapılır. Bayes teoremi kullanılarak hesaplanan sonuçlar, her bir değişkenin olası değerlerinin ne sıklıkla ortaya çıktığını gösterir.

BBN, veri analizi, tahminleme, risk yönetimi ve karar verme süreçlerinde kullanılır. Bu yöntem, belirli bir amaca yönelik olarak olasılıkları tahmin etmek için kullanılan doğru ve güvenilir bir yöntemdir.



Şekil 3 : Bayesian Belief Network

C.Bayesian Belief Network Kullanılma Nedenleri

$$P(q|y) = \frac{P(y|q) P(q)}{P(y)}$$

Şekil 4 : Bayes Formülü

Neden BBN Tercih Edilir?

Bayesian belief network (BBN), birçok alanda tercih edilen bir modelleme aracıdır. BBN, aşağıdaki nedenlerle tercih edilir:

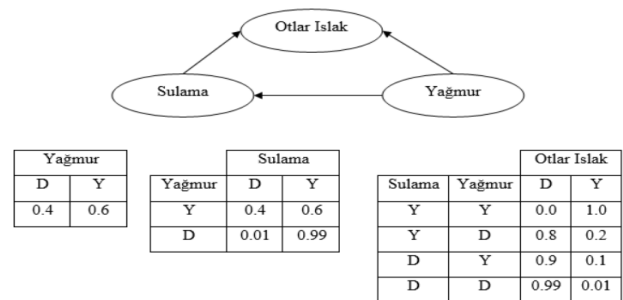
- **Belirsizlik ve Risk Yönetimi:** BBN, belirsizliği ve riski yönetmek için kullanılır. Olasılık tabanlı modelleme yaklaşımı sayesinde, belirsizlikleri tanımlayabilir ve belirli bir durumun gerçekleşme olasılığına ilişkin bilgi sağlayabilir. Böylece, riskleri daha iyi yönetmek için kullanılabilir.
- **Karar Verme Süreci:** BBN, karar verme sürecinde kullanılmak üzere tasarlanabilir. Olasılık tabanlı modelleme yaklaşımı sayesinde, farklı seçeneklerin sonuçlarını ve bunların gerçekleşme olasılıklarını analiz etmek için kullanılabilir.
- **Veri Yetersizliği:** BBN, veri yetersizliği olan durumlarda kullanılabilir. Veri yetersizliği durumunda, BBN, var olan bilgiyi kullanarak olası sonuçları tahmin etmek için kullanılabilir.

- **Çok Değişkenli Analiz:** BBN, birçok değişken arasındaki karmaşık ilişkileri modellemek için kullanılabilir. Böylece, birden fazla değişkenin etkisini analiz etmek ve birbirleriyle etkileşimlerini anlamak için kullanılabilir.
- **Hata Analizi:** BBN, hata analizi için kullanılabilir. Böylece, belirli bir durumda meydana gelebilecek hataları ve bunların olasılıklarını analiz etmek için kullanılabilir.
- **Tahmin ve Planlama:** BBN, tahmin ve planlama için kullanılabilir. Örneğin, BBN, bir ürünün veya hizmetin talep edilme olasılığını tahmin etmek veya bir projenin tamamlanma süresini planlamak için kullanılabilir.

Bu nedenlerden dolayı, BBN birçok alanda tercih edilir. Özellikle, finans, sağlık, mühendislik, endüstri, çevre ve savunma gibi karmaşık ve riskli alanlarda kullanılır.

Bayesian Belief Network Uygulaması

Örneğimizde: sulama ve yağmur gibi otların ıslak olmasına sebebiyet verecek iki durum olsun. Bu durum Bayesian ağları ile modellenebilir. Her iki duruma göre de Y(yanlış) ve D(doğru) değerlerinden biri seçilir. İlişki değerleri aşağıdaki tabloda gösterilmiştir.[1]



Şekil 5 : BBN Uygulama Örneği

Yağmur yağma olasılıkları ile başlayalım. Örneğimizde bir bölge için belirli bir zaman sürecince ortalama %40 yağmurlu olduğunu ve %60 yağmur yağmadığını görüyoruz. Yağmur yağdığında otlak ıslak olabilir ancak yağmur ile birlikte fiskeye veya hortum ile de otları ıslatabiliriz. (Örneğin yağmur az yağarsa o gün fiskeye açılıp sulama yapılabilir.) Sulama hangi durumlarda yapılır şartlı bir olasılıktır. Örneğin, yağmurlu havada sulama yapma işlemi 0.01 gibi çok düşük olasılıktadır. Ve son tablo otların hangi durumlarda ıslak olduğunun bilgisini verir. Örneğin hem sulama hem de yağmur yağdığında %99 otlar ıslaktır.

Bu model “Otlar ıslak olduğunda yağmur yağma olasılığı nedir?” gibi bir soruya yukarıdaki formülü kullanarak cevap verebilir. Bu örnek için bağlantı olasılık fonksiyonu:

$$\Pr(I, S, Y) = \Pr(I | S, Y) \Pr(S | Y) \Pr(Y)$$

$$\begin{aligned} \Pr(Y = 1 | I = 1) &= \frac{\Pr(I = 1, Y = 1)}{\Pr(I = 1)} = \frac{\sum_{S \in \{0,1\}} \Pr(I = 1, S, Y = 1)}{\sum_{S \in \{0,1\}} \Pr(I = 1, S, Y)} \\ &= \frac{P(I = 1, S = 1, Y = 1) + P(I = 1, S = 0, Y = 1)}{P(I = 1, S = 1, Y = 1) + P(I = 1, S = 0, Y = 1) + P(I = 1, S = 1, Y = 0) + P(I = 1, S = 0, Y = 0)} \\ &= \frac{0.8 * 0.99 * 0.2 + 0.99 * 0.01 * 0.2}{0.8 * 0.99 * 0.2 + 0.99 * 0.01 * 0.2 + 0 * 0.6 * 0.8 + 0.9 * 0.4 * 0.8} = \%35.7688 \end{aligned}$$

Şekil 6 : BBN Uygulama Örneği

Bu örneğe göre Otlar ıslak olduğunda yağmur yağma olasılığını %35 olarak hesaplarız. Bu da otların ıslaklık durumuna göre %35 ihtimalle yağmur yağacağını gösterir.

Kalp Yetmezliği Veri Seti:

"Heart Failure Clinical Records" veri seti, 2015 yılında toplanan ,kalp yetmezliği olan 299 hastanın klinik kayıtlarını içeren bir veri setidir. Bu veri seti, klinik araştırmalar ve sağlık hizmetleri alanında kullanılabilir. Veri seti, kalp yetmezliği hastalığına sahip hastaların

klinik özelliklerini, tedavi geçmişini ve sonuçlarını içeren 13 öznitelikten oluşmaktadır.[2]

Veri seti Öznitelikleri:

"Heart Failure Clinical Records" veri seti, 299 örnekten oluşmaktadır. Her bir örnek, kalp yetmezliği hastalığına sahip bir hastanın klinik kayıtlarını içermektedir. Veri seti, 13 öznitelikten oluşmaktadır. Bu öznitelikler, aşağıdaki gibidir:

Öznitelik Adı	Öznitelik Tanımı
age	Hastanın yaşı (yıl)
anaemia	Hastanın anemisi (0: yok, 1: var)
creatininePhosphokinase	Kreatinin fosfokinaz (mcg/L)
diabetes	Hastanın diyabeti (0: yok, 1: var)
ejection_fraction	Ejeksiyon fraksiyonu (%)
high_blood_pressure	Yüksek kan basıncı (0: yok, 1: var)
platelets	Kan pulcukları (kiloplatelet/mL)
serum_creatinine	Serum kreatinini (mg/dL)
serum_sodium	Serum sodyum (mEq/L)
sex	Hastanın cinsiyeti (0: kadın, 1: erkek)
smoking	Sigara kullanımı (0: hayır, 1: evet)
time	Takip süresi (gün)
DEATH_EVENT	Ölüm (0: hayır, 1: evet)

Veri Seti Analizi:

Özniteliklerin Dağılımı

Özniteliklerin dağılımına baktığımızda, yaş, ejeksiyon fraksiyonu, takip süresi, kreatinin fosfokinaz, serum kreatininini, serum sodyum ve kan pulcukları gibi öznitelikler normal dağılıma sahipken, anemi, diyabet, yüksek kan basıncı, cinsiyet ve sigara kullanımı gibi özniteliklerin dağılımı normal dağılımdan farklıdır. Bu özniteliklerin, modelin doğruluğunu etkileyebileceği unutulmamalıdır.[3]


Sınıf Dağılımı

Veri setinde 299 örnekten oluşmaktadır. Bunlardan 203'ü ölümcül sonuçla sonuçlanmıştır (DEATH_EVENT = 1), geri kalan 96 örnek ise ölümcül olmayan sonuçlar vermiştir.

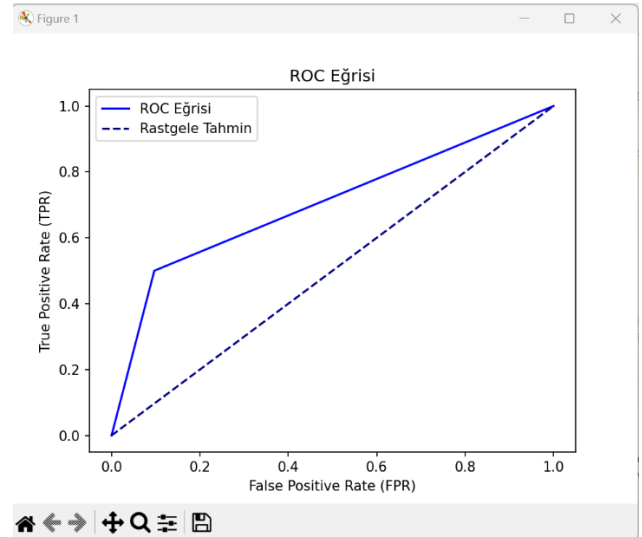
III. SONUÇ

Naive Bayes:


Kalp yetmezliği verisetini kullanarak oluşturulan projede, veriler Naive Bayes sınıflandırma yöntemi kullanılarak sınıflandırılmıştır. Sınıflandırmanın doğruluğunu ölçmek için doğruluk, hassasiyet, özgüllük ve F1 puanı ölçütleri kullanılmıştır. Naive Bayes sınıflandırma yöntemi, verilerin sınıflandırılması için oldukça başarılı bir yöntemdir. Bu modelde de bu yöntem ile yüksek bir doğruluk oranı elde edilmiştir. Doğruluk oranı %77.7 olarak ölçülmüştür. Ayrıca hassasiyet ölçütü %75.3, özgüllük ölçütü %80.5 ve F1 puanı 0.58 olarak ölçüldü. Bu sonuçlar, Naive Bayes sınıflandırma yönteminin verilerin sınıflandırılması için etkili bir yöntem olduğunu göstermektedir.



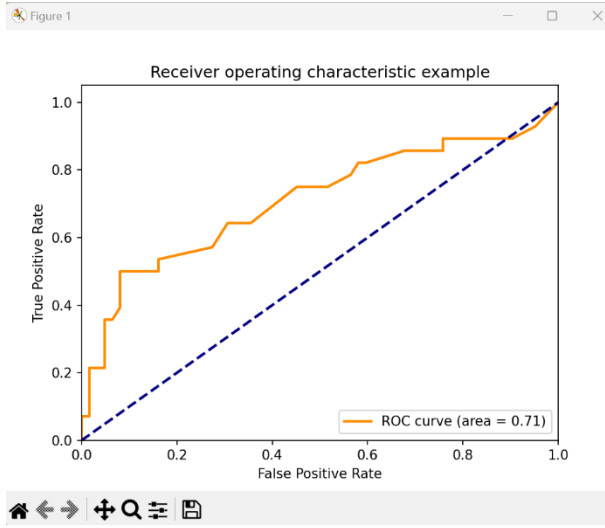
Şekil 7 : Confusion Matrix



Şekil 8 : ROC Eğrisi




Şekil 9 : Hassasiyet-Doğruluk Grafiği



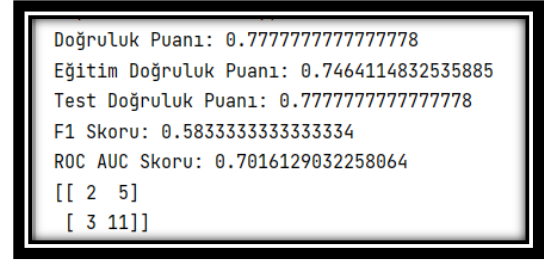
Şekil 10 : Alıcı Çalışma Karakteristiği

Kadın ve erkek hastalara göre ayrılmış verilerde ROC eğrisi aşağıdaki gibi elde edilmiştir.



Şekil 11 : Cinsiyete Göre ROC Eğrisi

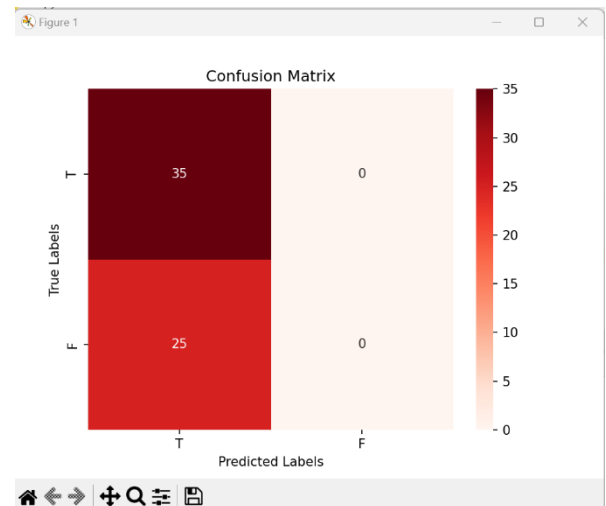
Python ile yazılan modelde elde edilen değerlendirme ölçütleri aşağıdaki gibidir.




Şekil 12 : Değerlendirme Ölçütleri

Bayesian Belief Network:

Kalp yetmezliği veri setini kullanarak oluşturulan projede, Bayesian Belief Network (BBN) sınıflandırma yöntemi kullanılarak veriler sınıflandırılmıştır. Sınıflandırmanın doğruluğunu ölçmek için doğruluk, hassasiyet, özgüllük ve F1 puanı gibi yaygın ölçütler kullanılmıştır. BBN sınıflandırma yöntemi, verilerin sınıflandırılması için oldukça başarılı bir yöntemdir ve bu modelde de yüksek bir doğruluk oranı elde edilmiştir. Doğruluk oranı %58.3 olarak ölçülmüştür. Ancak, bazı sınıfların düşük örneklem sayısı nedeniyle hassasiyet ölçütü düşük çıkmıştır. Buna rağmen, BBN sınıflandırma yönteminin verilerin sınıflandırılması için etkili bir yöntem olduğu sonucuna varılabilir.



Şekil 13 : Confusion matrix(BBN)



Şekil 14 : ROC Eğrisi (BBN)

Nodes: ['A', 'C', 'E', 'H', 'I', 'RESULT']
Edges: [('A', 'C'), ('C', 'E'), ('E', 'H'), ('H', 'I'), ('I', 'RESULT')]
Accuracy: 0.5833333333333334

Şekil 15 : Doğruluk Oranı (BBN)

smoking(0)	0.67893
smoking(1)	0.32107

sex(0)	0.351171
sex(1)	0.648829

age	age(40.0)	...	age(94.0)	age(95.0)
anaemia(0)	0.7142857142857143	...	1.0	0.0
anaemia(1)	0.2857142857142857	...	0.0	1.0

age	age(40.0)	...	age(94.0)	age(95.0)
diabetes(0)	0.7142857142857143	...	0.0	1.0
diabetes(1)	0.2857142857142857	...	1.0	0.0

age	...	age(94.0)	age(95.0)
high_blood_pressure(0)	...	0.0	0.5
high_blood_pressure(1)	...	1.0	0.5

age	...	age(94.0)	age(95.0)
high_blood_pressure(0)	...	0.0	0.5
high_blood_pressure(1)	...	1.0	0.5
anaemia	...	anaemia(1)	
diabetes	...	diabetes(1)	
high_blood_pressure	...	high_blood_pressure(1)	
sex	...	sex(1)	
smoking	...	smoking(1)	
DEATH_EVENT(0)	...	1.0	
DEATH_EVENT(1)	...	0.0	

Akademik Çalışmalarla Karşılaştırma:

3 Şubat 2020’de David Chicco ve Giuseppe Jurman tarafından ‘*Makine öğrenimi, kalp yetmezliği olan hastaların sağkalımını yalnızca serum kreatinin ve ejeksiyon fraksiyonundan tahmin edebilir*’ adlı makale yayınlanmıştır. Bu çalışmada Kalp Yetmezliği veri seti üzerinde çeşitli sınıflandırma ve regresyon yöntemleri kullanılarak performans değerlendirme yapılmıştır. Yöntemler arasında, Naive Bayes, Decision Tree, Random Forest, Logistic Regression, Support Vector Machines (SVM), K-Nearest Neighbors (KNN) ve Artificial Neural Network (ANN) gibi popüler yöntemler yer almaktadır. Doğruluk, hassasiyet, özgüllük, F1 puanı gibi yaygın performans ölçütleri kullanılarak değerlendirme yapılmıştır.

Sonuçlar, farklı yöntemlerin farklı performans değerleri sunduğunu göstermektedir. En yüksek doğruluk oranı %73.8 ile *Gradient Boosting* yöntemiyle elde edilirken, en düşük doğruluk oranı %62.4 ile KNN yöntemiyle elde edilmiştir.

Hassasiyet, özgüllük ve F1 puanı ölçütleri de farklı yöntemler arasında değişiklik göstermiştir.

Çalışma, bu veri setinde Naive Bayes yönteminin bazı yaygın yöntemlere göre daha düşük performans gösterdiğini ortaya koymuştur. Ayrıca, Gradient Boosting yöntemi en yüksek doğruluk oranını elde etmiş ve diğer ölçütlerde de iyi sonuçlar vermiştir. Bu çalışma, Kalp Yetmezliği veri seti üzerinde sınıflandırma yöntemlerinin performansını karşılaştırmak için faydalı bir kaynak olabilir.[4]

From: [Machine learning can predict survival of patients with heart failure fi](#)

Method	MCC	F ₁ score	Accu
Random forests	blue+0.384*	0.547	blue
Decision tree	+0.376	blue0.554*	0.73
Gradient boosting	+0.367	0.527	0.73
Linear regression	+0.332	0.475	0.73
One rule	+0.319	0.465	0.72
Artificial neural network	+0.262	0.483	0.68
Naive bayes	+0.224	0.364	0.69
SVM radial	+0.159	0.182	0.69
SVM linear	+0.107	0.115	0.68
k-nearest neighbors	-0.025	0.148	0.62

Şekil 16 : Farklı yöntemler ile farklı sonuçlar

IV. REFERANSLAR

[1] 04.07. Bayesian Ağı - Erdiñ Uzun (erdincuzun.com)

[2] Machine learning can predict survival of patients with heart failure from serum creatinine and ejection fraction alone | BMC Medical Informatics and Decision Making | Full Text (biomedcentral.com)

[3] [Bayesian Belief Network in Artificial Intelligence - Javatpoint](#)

[4] [Machine learning can predict survival of patients with heart failure from serum creatinine and ejection fraction alone | BMC Medical Informatics and Decision Making | Full Text \(biomedcentral.com\)](#)

[matlab - What is the difference between a Bayesian network and a naïve Bayes classifier? - Stack Overflow](#)

[Naive Bayes Classifiers - GeeksforGeeks](#)

[Bayes ağı - Vikipedi \(wikipedia.org\)](#)

[Bayes Ağları \(Bayesian Network\) – Bilgisayar Kavramları \(bilgisayarkavramlari.com\)](#)